



MACHINE LEARNING




# SUPPORT VECTOR MACHINE (SVM)

PRÉSENTATION



# TRAVAIL ÉLABORÉ PAR



**AHMED AZIZ  
MHIRI**



**MOHAMED  
RAMI ZAIRI**




**AHMED JERBI**



**HOUSSEM  
SLAIMI**



**AHMED AZIZ  
WADANI**





# PLAN

- Introduction aux SVM
- Principe de fonctionnement
- Formulation mathématique
- Types de SVM
- Fonctionnement du noyau
- Paramètres importants
- Avantages des SVM
- Limitations des SVM
- Applications des SVM
- Exemples concrets
- Conclusion



# INTRODUCTION


**Les machines à vecteurs de support (SVM) sont des algorithmes d'apprentissage supervisé utilisés principalement pour les tâches de classification et de régression**

les SVM se distinguent par leur capacité à trouver l'hyperplan optimal qui sépare les différentes classes dans un espace de données, maximisant ainsi la marge entre les points de données des différentes classes






# PRINCIPE DE FONCTIONNEMENT




## REPRÉSENTATION DES DONNÉES

Les données d'entraînement sont représentées sous forme de points dans un espace de caractéristiques. Chaque point correspond à un vecteur de caractéristiques, et chaque point appartient à une classe



## SÉPARATION DES CLASSES


L'objectif est de trouver un hyperplan qui sépare les données de différentes classes. Pour les données linéairement séparables, il existe potentiellement plusieurs hyperplans qui pourraient séparer les classes



## HYPERPLAN OPTIMAL


Parmi tous les hyperplans possibles, le SVM choisit celui qui maximise la marge, c'est-à-dire la distance entre l'hyperplan et les points de données les plus proches de chaque classe. Cette marge maximale assure une meilleure généralisation du modèle aux nouvelles données






## FORMULATION MATHÉMATIQUE

La recherche de l'hyperplan optimal est formulée comme un problème d'optimisation. On minimise une fonction objectif sous contraintes, souvent résolue par des techniques comme les multiplicateurs de Lagrange




## DONNÉES NON LINÉAIRES

Lorsque les données ne sont pas linéairement séparables, le SVM utilise des fonctions noyaux (kernels) pour transformer les données dans un espace de plus haute dimension où une séparation linéaire devient possible



## SOFT MARGIN SVM

Pour gérer les données bruitées ou les outliers, une variante appelée "soft margin SVM" est utilisée. Elle introduit des variables de relaxation qui permettent à quelques points de données de se trouver du mauvais côté de l'hyperplan




## PRÉDICTION

Une fois le modèle entraîné, pour classer un nouveau point de données, le SVM évalue de quel côté de l'hyperplan le point se situe. Cela détermine la classe attribuée au nouveau point



# FORMULATION MATHÉMATIQUE




## 1. SVM Linéaires

Objectif:

Trouver l'hyperplan qui sépare le mieux les deux classes de données dans un espace de caractéristiques. Pour un ensemble de données  $(x_i, y_i)$  où  $x_i \in \mathbb{R}^n$  et  $y_i \in \{-1, 1\}$ , l'hyperplan est défini par l'équation  $w \cdot x + b = 0$ .

# FORMULATION MATHÉMATIQUE



## 1. SVM Linéaires

Formulation du Problème de l'Optimisation:


Minimiser la fonction objectif suivante :

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

Sous contraintes :  $y_i(w \cdot x_i + b) \geq 1, \forall i$



# FORMULATION MATHÉMATIQUE



## 1. SVM Linéaires

### Problème Dual

Le problème dual permet de résoudre plus efficacement le problème de SVM :

Maximiser la fonction suivante :

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i \cdot x_j$$

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i \cdot x_j$$


Sous contraintes :  $\sum_{i=1}^N \alpha_i y_i = 0$

$$0 \leq \alpha_i \leq C, \forall i$$

où  $\alpha_i$  sont les multiplicateurs de Lagrange et  $C$  est un paramètre de régularisation



# FORMULATION MATHÉMATIQUE




## 2. SVM Non Linéaires

Les SVM non linéaires utilisent un trucage appelé le noyau (kernel) pour transformer les données dans un espace de caractéristiques de dimension supérieure où un hyperplan linéaire peut être utilisé pour la séparation



# FORMULATION MATHÉMATIQUE




## 2. SVM Non Linéaires

### Noyaux Courants

- Noyau linéaire :  $K(x_i, x_j) = x_i \cdot x_j$
- Noyau polynomial :  $K(x_i, x_j) = (x_i \cdot x_j + 1)^d$
- Noyau gaussien (RBF) :  
 $K(x_i, x_j) = \exp(-\|x_i - x_j\|^2 / 2\sigma^2)$   
 $= \exp(-2\sigma^2 \|x_i - x_j\|^2)$



# FORMULATION MATHÉMATIQUE



## 2. SVM Non Linéaires

Formulation du Problème de l'Optimisation avec Noyau

Maximiser la fonction suivante :


$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

Sous contraintes :  $\sum_{i=1}^N \alpha_i y_i = 0$   
 $0 \leq \alpha_i \leq C, \forall i$



# FORMULATION MATHÉMATIQUE



## Décision

La fonction de décision pour prédire la classe d'un nouveau point  $x$  est donnée par :

Pour SVM linéaire :

$$f(x) = \text{sign}(w \cdot x + b)$$

Pour SVM non linéaire :

$$f(x) = \text{sign}\left(\sum_{i=1}^N \alpha_i y_i K(x_i, x) + b\right)$$






# TYPES DES SVM

**SVM linéaire**

**SVM non linéaire**



# SVM LINEAIRE


Les machines à vecteurs de support (SVM) linéaires sont des modèles d'apprentissage automatique utilisés pour la classification et la régression. Leur principe repose sur la recherche d'un hyperplan qui sépare de manière optimale les données en classes distinctes dans un espace de caractéristiques de dimension supérieure. L'objectif est de maximiser la marge, c'est-à-dire la distance entre l'hyperplan et les échantillons les plus proches de chaque classe, ce qui permet d'obtenir un modèle de classification robuste et peu sensible au surajustement.



# SVM NON LINÉAIRE

Les machines à vecteurs de support (SVM) non linéaires étendent le concept des SVM linéaires pour traiter des ensembles de données non linéairement séparables. Au lieu de chercher un hyperplan linéaire, les SVM non linéaires utilisent des fonctions de noyau pour projeter les données dans un espace de caractéristiques de dimension supérieure, où elles peuvent être séparées par un hyperplan. Les fonctions de noyau permettent de capturer des relations non linéaires entre les caractéristiques des données, ce qui les rend plus flexibles et capables de modéliser des structures plus complexes.





# DIFFÉRENCE ENTRE LES DEUX TYPES DE SVM

## SVM LINÉAIRE

- Recherche un hyperplan linéaire qui sépare les données en classes distinctes
- Utilise un produit scalaire pour calculer les distances entre les points et l'hyperplan
- Convient aux ensembles de données linéairement séparables

## SVM NON LINÉAIRE

- Utilise des fonctions de noyau pour projeter les données dans un espace de caractéristiques de dimension supérieure
- Recherche un hyperplan non linéaire qui sépare les données dans cet espace de caractéristiques
- Peut gérer des ensembles de données non linéairement séparables en transformant les données dans un espace où elles le sont






# FONCTIONNEMENT DE NOYAU


**Transformation Implicite :** Au lieu de transformer explicitement chaque point de données  $x$  dans un espace de caractéristiques de dimension supérieure  $\phi(x)$ , nous utilisons une fonction de noyau  $K(x_i, x_j)$  qui calcule directement le produit scalaire dans cet espace transformé :  $K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$

**Maximisation de la Fonction Duale :** La formulation du problème dual des SVM fait largement appel aux produits scalaires des paires de points de données. En utilisant des noyaux, nous pouvons remplacer ces produits scalaires par des fonctions de noyau, évitant ainsi le calcul explicite des transformations dans l'espace de caractéristiques

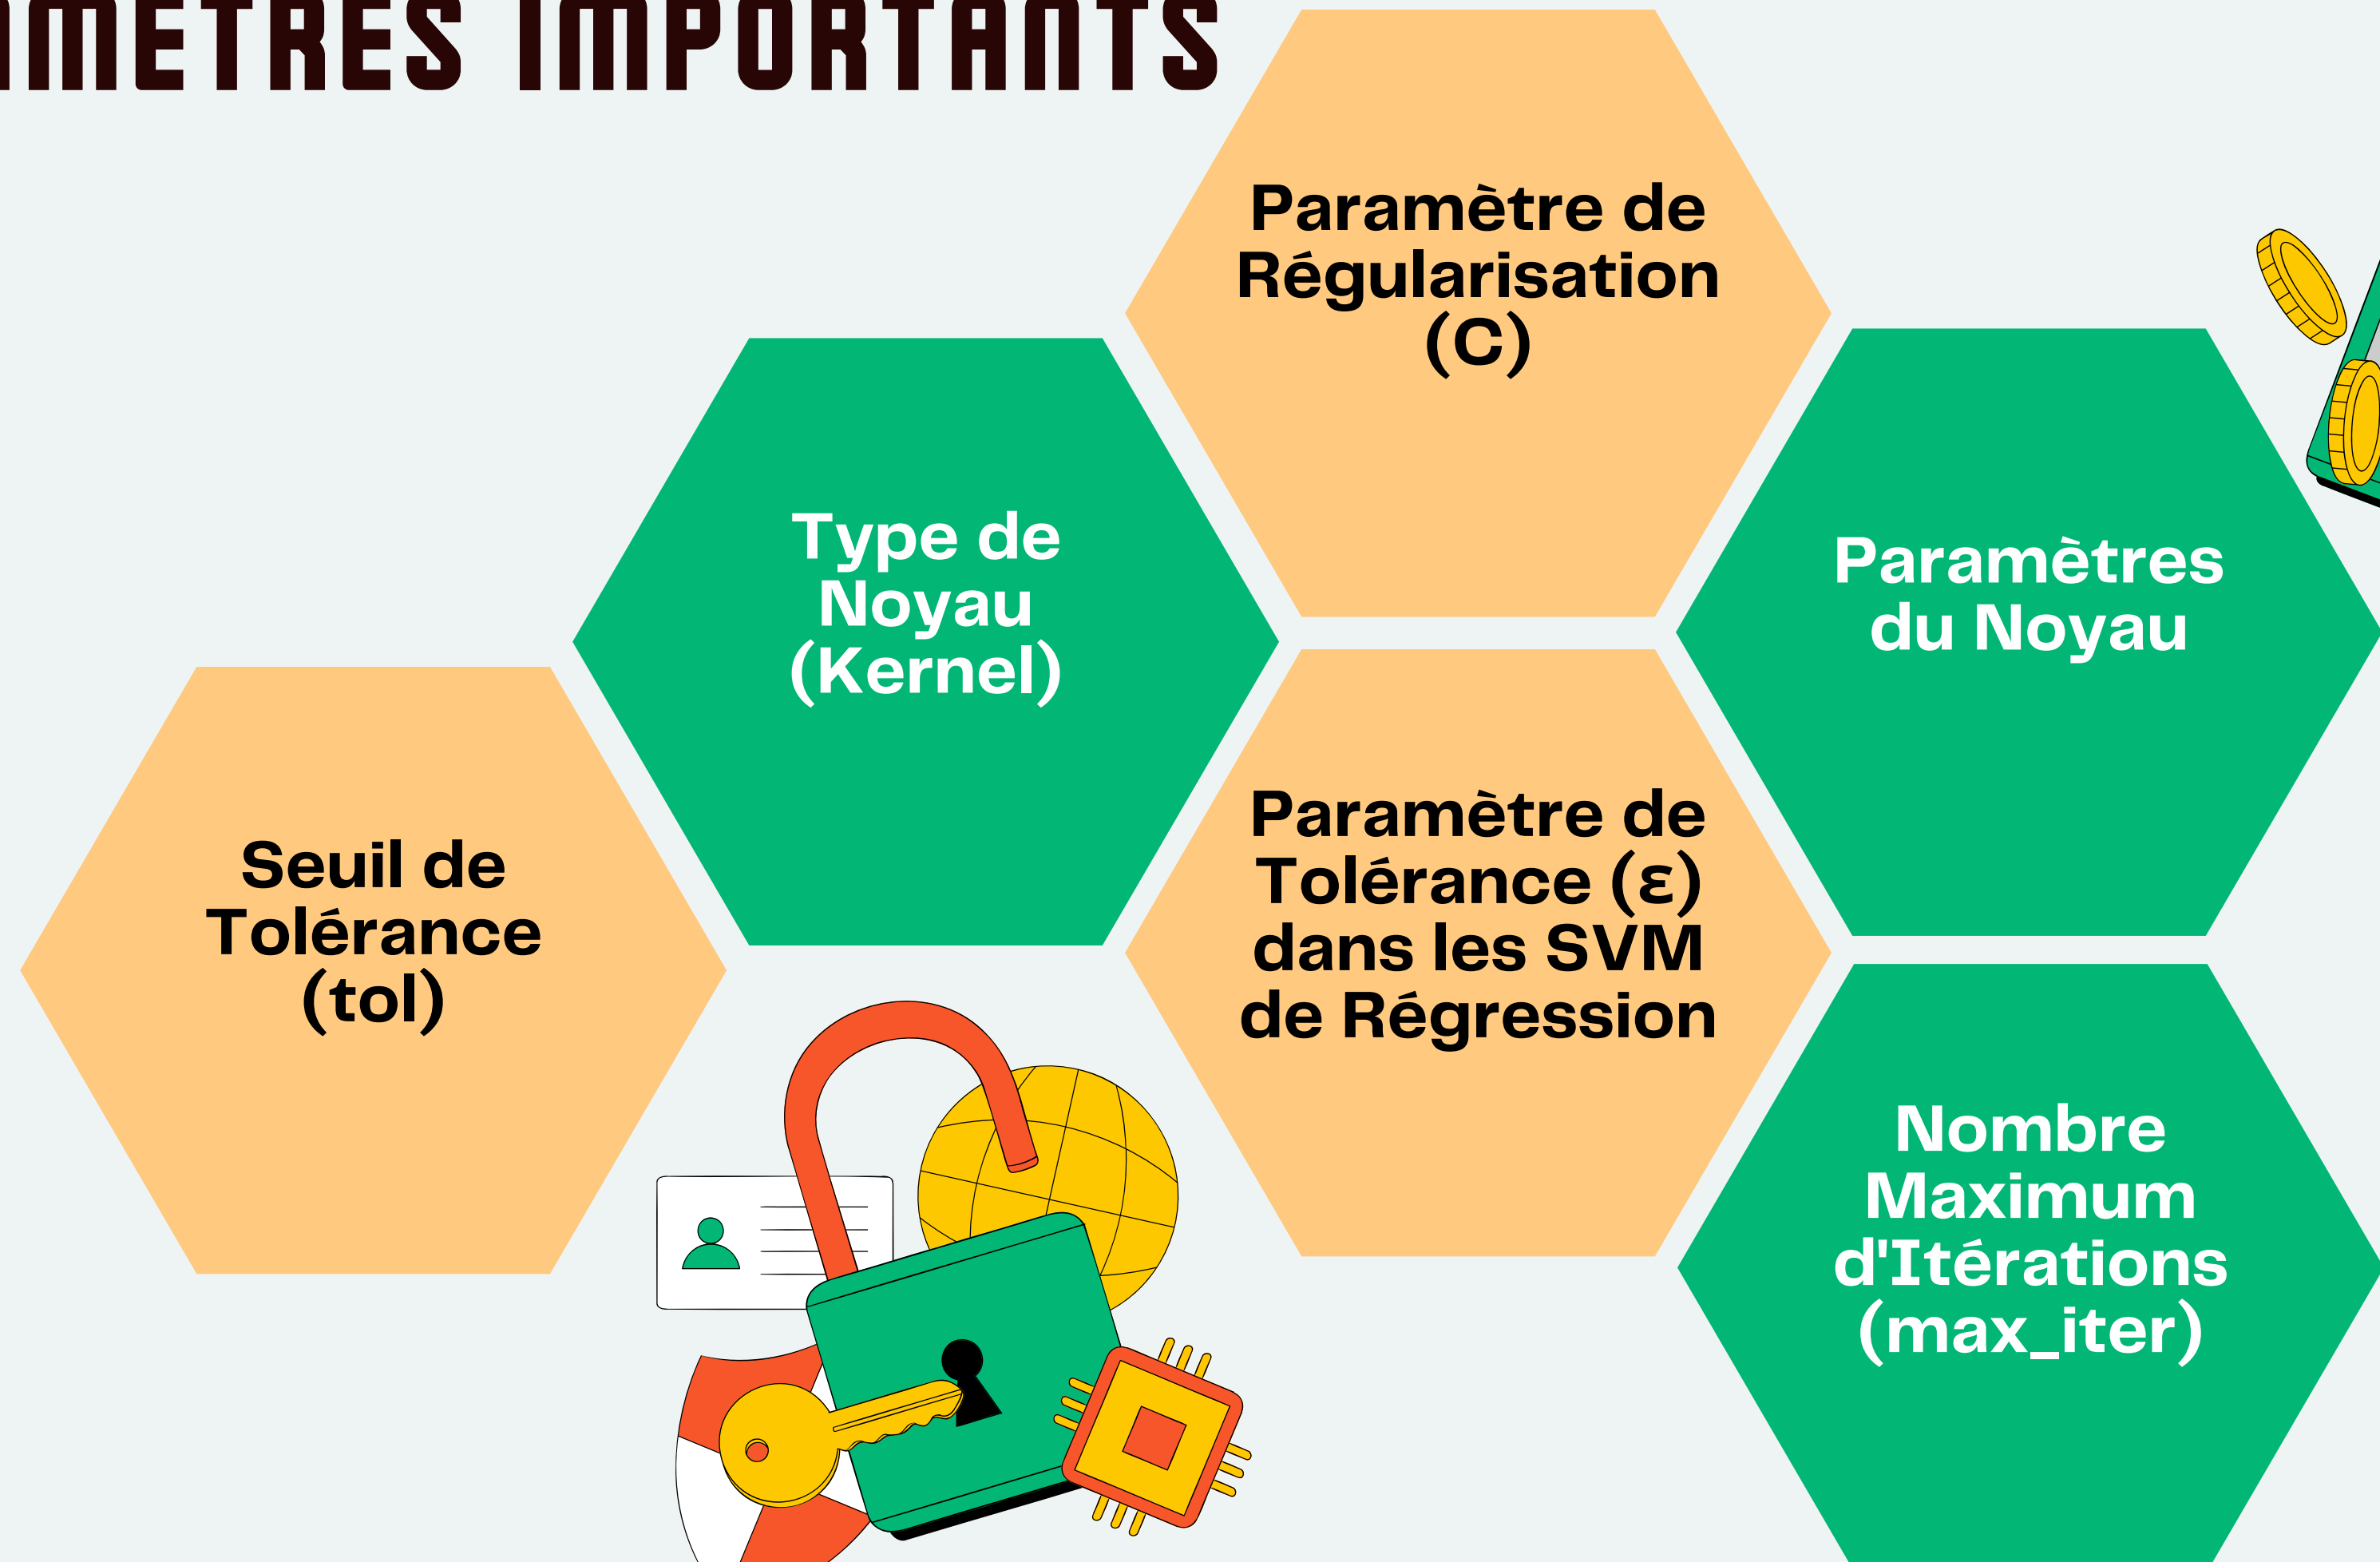


```
SVC(kernel='rbf', gamma=0.02).fit(X, y)
```

$\gamma$   
0.02



# PARAMÈTRES IMPORTANTS



# AVANTAGES DE SVM

**Efficacité dans les espaces de grande dimension**

**Capacité à gérer les ensembles de données de petite taille**

**Bonne généralisation**

**Flexibilité dans le choix des fonctions de noyau**



# LIMITES DE SVM



Sensibilité aux paramètres

Complexité computationnelle

Difficulté à interpréter les résultats

Sensibilité au bruit





# APPLICATIONS DES SVM



01

## CLASSIFICATION

### DE TEXTES ET D'IMAGES

Les SVM sont utilisés pour classifier des documents texte en fonction de leur contenu ou pour identifier des objets dans des images. Par exemple, ils peuvent différencier des e-mails en spam et non-spam.



02

## PRÉVISION FINANCIÈRE


Les SVM peuvent être appliqués à la prévision des marchés financiers en analysant des tendances et en prédisant des mouvements de prix basés sur des données historiques.





03

## DÉTECTION DE FRAUDE

Les SVM peuvent aider à détecter des comportements frauduleux dans des transactions financières en identifiant des modèles anormaux dans les données.





# CONCLUSION

LES SUPPORT VECTOR MACHINES (SVM) SONT DES OUTILS PUISSANTS DANS LE DOMAINE DE L'APPRENTISSAGE AUTOMATIQUE, OFFRANT DES SOLUTIONS EFFICACES POUR DES TÂCHES DE CLASSIFICATION ET DE RÉGRESSION. LEUR CAPACITÉ À TROUVER L'HYPERPLAN OPTIMAL POUR SÉPARER LES CLASSES EN FAIT UNE MÉTHODE ROBUSTE ET FIABLE.

